

Uniwersytet Warszawski
Wydział Nauk Ekonomicznych

Michał Budzyński
Nr albumu: 441444

Analiza rynku muzycznego Spotify

Praca licencjacka
na kierunku: Informatyka i Ekonometria

Praca wykonana pod kierunkiem
dr. hab. Katarzyny Kopczewskiej, prof. ucz.
z Katedry Data Science
WNE UW

Warszawa, czerwiec 2024

Oświadczenia kierującego pracą

Oświadczam, że niniejsza praca została przygotowana pod moim kierunkiem i stwierdzam, że spełnia ona warunki do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

* Oświadczam, że mój udział w artykule naukowym, który stanowi część pracy dyplomowej wynosi%, zaś suplement do pracy został napisany samodzielnie przez dyplomanta(ów).

** skreślić jeśli nie dotyczy*

Data

Podpis kierującego pracą

*Oświadczenie autora pracy***

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

* Oświadczam, że mój*** udział w artykule naukowym, który stanowi część pracy dyplomowej wynosi% (nie mniej niż 60%), zaś suplement do pracy został napisany przeze mnie***.

** skreślić jeśli nie dotyczy*

Data

Podpis autora pracy

*** każdy ze współautorów studentów składa oświadczenie osobno*

**** w przypadku współautora studenta należy oświadczyć wkład merytoryczny i procentowy*

Streszczenie

Niniejsze badanie ma na celu rozpoznanie charakterystycznych atrybutów utworów znajdujących się w listach przebojów oraz zidentyfikowanie preferencji konsumentów względem trendujących utworów. W tym celu analizie poddano dane o utworach, które w latach 2020-2021 przynajmniej raz wystąpiły w zestawieniu „Top 200 Weekly (Global)”, tworzonego przez platformę Spotify. W związku z powyższym przeprowadzono klastrowanie K-średnich z metryką euklidesową odległości oraz zastosowano szereg testów i procedur statystycznych. Wyniki przeprowadzonego badania jednoznacznie wskazały na istnienie heterogeniczności preferencji konsumentów względem trendujących utworów muzycznych. Ponadto rozpoznana została również struktura rynkowa, która pozwoliła na określenie procentowego udziału charakterystycznych cech utworów w ogóle popularnych kompozycji muzycznych. Rozważaniom poddano również zjawisko „TikTok-to-Spotify pipeline” stanowiące swoisty kanał promocyjny pomiędzy platformami oraz jego podłoże, wpływ na branżę muzyczną i kształtowanie się preferencji konsumentów.

Słowa kluczowe

ekonomia behawioralna, ekonomia kultury, TikTok-to-Spotify pipeline, hit song science, music information retrieval, Spotify, TikTok, uczenie maszynowe

Dziedzina pracy (kody wg programu Erasmus)

Ekonomia (14300)

Klasyfikacja tematyczna

Tytuł pracy w języku angielskim

Analysis of the Spotify music market

SPIS TREŚCI

WSTĘP	5
ROZDZIAŁ I Przegląd literatury.....	7
1.1. Digitalizacja branży muzycznej.....	7
1.2. Spotify jako globalny lider na rynku platform specjalizujących się w streamingu muzyki.....	10
1.3. Rola Spotify w kształtowaniu dochodu artystów.....	12
1.4. Znaczenie atrybutów utworu.....	14
ROZDZIAŁ II Opis danych i metodologia badania.....	15
2.1. Bazy danych.....	15
2.2. Normalizacja zmiennych.....	17
2.3. Klastrowanie K-średnich.....	18
2.4. Porównania równości zmiennych w całej populacji oraz porównania parami.....	19
ROZDZIAŁ III Badanie empiryczne.....	22
3.1. Klastrowanie.....	22
3.1.1. Wybór ilości klastrow.....	22
3.1.2. Analiza struktury klastrow.....	24
3.1.3. Empiryczna charakterystyka klastrow.....	26
3.2. Zjawisko „TikTok-to-Spotify pipeline”.....	29
3.2.1. Teoretyczne uzasadnienie.....	29
3.2.2. Empiryczne badanie zjawiska	31
3.3. Analiza cech utworów między klastrami.....	33
3.3.1. Porównanie cech utworów we wszystkich klastrach.....	33
3.3.2. Porównanie cech klastrow parami.....	34
3.4. Walidacja wyników analizy.....	35
3.5. Wnioski z przeprowadzonej analizy.....	36
PODSUMOWANIE	38
BIBLIOGRAFIA	39

ZESTAWIENIE SPISÓW.....	45
ZAŁĄCZNIKI.....	47

WSTĘP

Rozwój technologii cyfrowych i przemiany w strukturach społeczno-ekonomicznych stwarzają nowe możliwości i wyzwania na rynku muzycznym. Kluczowym elementem tych zmian jest rosnące znaczenie platform streamingowych¹. Spotify, jako jeden z liderów wśród wspomnianych platform, wywiera znaczący wpływ na sposób dystrybucji i konsumpcji muzyki, co czyni je interesującym obiektem badań. Na podwalinach cyfryzacji branży muzycznej wykształciły się nowe obszary badawcze, takie jak „*Music Information Retrieval*” (MIR, pl: pozyskiwania informacji muzycznych) oraz „*Hit Song Science*” (HSS, pl: nauka o przebojach muzycznych). Obszary te są szczególnie istotne dla osób zawodowo związanych z branżą muzyczną (np. artyści muzyczni, managerowie, wydawnictwa muzyczne), ale również wspomagają inne dyscypliny m.in. psychiatrię, medycynę czy socjologię (Schriewer oraz Bulaj, 2016; Benetos, Ragano oraz Sgroi, 2022). Wiele badań wykorzystuje zagadnienia MIR oraz HSS w celu tworzenia modeli uczenia maszynowego, służących do predykcji komercyjnego sukcesu utworów na podstawie ich muzycznych atrybutów, takich jak taneczność, energiczność czy pozytywność (ang. *valence*). Jednakże, wśród literatury naukowej brakuje informacji na temat aktualnej struktury rynku muzycznego oraz aktualnych preferencji konsumentów względem najpopularniejszych utworów. Biorąc pod uwagę doniesienia grupy Vox (2022) o zaistnieniu procesu „*TikTok-to-Spotify pipeline*” (kanał promocji utworów z TikTok’a na Spotify) oraz określenie platformy TikTok jako swego rodzaju prekursora wyznaczającego nowe trendy muzyczne (ang. *trendsetter*), informacje o aktualnej strukturze rynku muzycznego oraz preferencji konsumentów wydają się być tym bardziej istotne.

Niniejsza praca ma na celu wypełnienie powstałej luki badawczej oraz zweryfikowanie hipotezy o heterogeniczność preferencji względem trendujących utworów muzycznych. Aby to osiągnąć, zdecydowano się na zidentyfikowanie charakterystycznych cech popularnych utworów, a przez to określenie aktualnej sylwetki i struktury rynku muzycznego jako procentowego udziału poszczególnych atrybutów muzycznych w całości zbioru najpopularniejszych utworów. Istotnym celem badania jest także rozpoznanie aktualnych preferencji konsumentów względem trendujących utworów. Badanie weryfikuje także

¹ Frazy i wyrazy ‘platforma streamingowa’, ‘streamować’, ‘streaming’ to spolszczenia od angielskiego wyrazu ‘stream’, które są powszechnie wykorzystywane w terminologii dotyczącej rynku muzycznego. Tłumaczenie oparte na frazie ‘strumieniowanie’ nie przyjęło się i nie jest wykorzystywane w dyskusji naukowej oraz popularno-naukowej. W analogiczny sposób można odnieść się do wyrazów ‘trendujący’ czy ‘playlista’ – są to spolszczenia, dla których nie ma powszechnie wykorzystywanych odpowiedników wprost z języka polskiego.

istnienie zjawiska „TikTok-to-Spotify pipeline”. Niniejsza praca jest istotnym wkładem w obszary MIR oraz HSS, wpisując się w ramy ekonomii kultury oraz ekonomii behawioralnej.

Strukturę pracy zorganizowano w trzech rozdziałach. Pierwszy rozdział zawiera w sobie przegląd literatury oraz teoretyczne aspekty digitalizacji branży muzycznej, na podstawie których wysnuto hipotezę badawczą głoszącą, iż istnieje heterogeniczność preferencji konsumentów względem trendujących utworów muzycznych. Ponadto, rozdział ten zarysowuje rolę serwisu Spotify na rynku platform streamingowych oraz wpływ wspomnianego medium na kształtowanie się zarobków artystów muzycznych. Przybliżone zostały również teoretyczne podstawy obszarów „Hit Song Science” oraz „Music Information Retrieval”. Rozdział drugi prezentuje opis baz danych oraz zmiennych użytych w badaniu. Poza tym, opisana została w nim również metodologia badawcza, w tym techniki klastrowania oraz zastosowane narzędzia statystyczne. W trzecim, ostatnim rozdziale, przeprowadzona została analiza właściwa mająca za zadanie uzyskanie wyjaśnienia na przedstawione wcześniej cele badawcze. Przy tej okazji, dodatkowym rozważaniom poddano również zjawisko „TikTok-to-Spotify pipeline”. Rozdział ten zawiera również wnioskowanie na podstawie wyników przeprowadzonej analizy. Całość analizy wykonana została w języku programowania *Python* z wykorzystaniem bibliotek *pandas*, *numpy*, *statsmodels*, *scipy*, *pylab*, *seaborn*, *matplotlib*, *statistics* oraz *sklearn*.

ROZDZIAŁ I

Przegląd literatury

W tym rozdziale dokonano szczegółowego przeglądu literatury dotyczącej digitalizacji branży muzycznej, analizując zmiany w dystrybucji i konsumpcji muzyki oraz ich wpływ na role wydawnictw muzycznych w karierze artysty. Na tej podstawie sformułowano hipotezę badawczą. Omówiono również proces „mediamorfozy” oraz przedstawiono rolę Spotify jako globalnego lidera na rynku platform streamingowych, analizując jego strategie i wpływ na dochody artystów. Na podstawie prac empirycznych opisano koncepcje dziedziny „Hit Song Science” i „Music Information Retrieval” oraz ich znaczenie dla innych dyscyplin nauki.

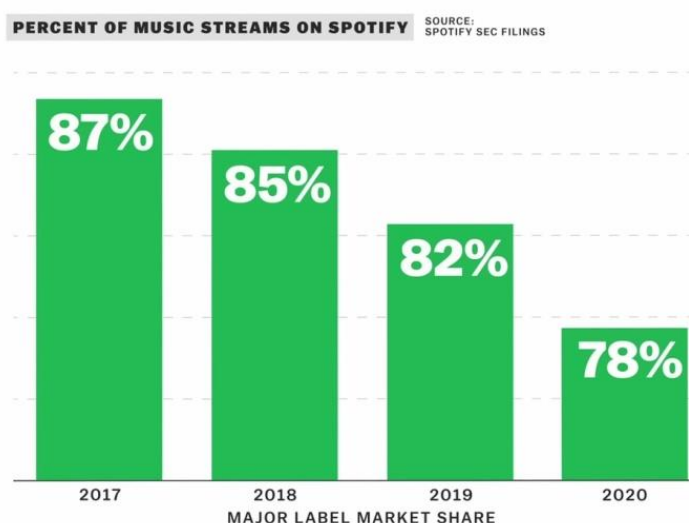
1.1. Digitalizacja branży muzycznej

W przeszłości przychody artystów oraz wytwórni muzycznych skupione były głównie wokół fizycznej sprzedaży płyt oraz nagrań (Hracs oraz Webster, 2020). Wzmoczony rozwój technologiczny mający miejsce pod koniec XX oraz na początku XXI wieku dotknął swym działaniem również branżę muzyczną i spowodował ogromne zmiany nie tylko w strukturze przychodów na rynku, ale również strategiach marketingowych, strukturze konsumpcji oraz dystrybucji muzyki, jak i roli wytwórni muzycznych w karierze artystów (Kaimann, Tanneberg oraz Cox, 2020; Borghi i inni, 2012).

Cyfryzacja branży muzycznej może być uznana jako jeden z rodzajów procesu określanego w naukach socjologicznych jako „mediamorfoza” (ang. *mediamorphosis*). Termin „mediamorfozy” w ujęciu ogólnym został opisany przez Rogera Fidlera (1997), a jego bardziej precyzyjna definicja zaproponowana została przez Kowalskiego (2001) jako „proces złożony, który dokonuje się pomiędzy subiektywnymi potrzebami odbiorców, konsumentów, klientów (potrzeby kulturowe), stanem konkurencji na rynku mediów, istniejącą strukturą polityczną i jej zdolnością do uwzględniania różnicujących się potrzeb i oczekiwań a innowacjami społecznymi i technologicznymi [...]”. Proces digitalizacji branży muzycznej może być uznany jako szczególny rodzaj „mediamorfozy” – mianowicie „mediamorfozy substytucyjnej”. Model substytucyjny oznacza proces, w którym media tradycyjne są wypierane przez nowe media i technologie cyfrowe (Jakubowicz, 2011). Tradycyjny model biznesowy zakładał, że konsumenci nabywają płyty CD, bądź inne nośniki nagrań, w celu konsumpcji twórczości wybranego artysty. Digitalizacja w branży muzycznej

pozwoili użytkownikom na łatwy dostęp do znacznie większego zbioru twórczości artystów z całego świata poprzez użytkowanie aplikacji streamujących muzykę, takich jak Spotify, SoundCloud, Deezer czy Apple Music. Wlömert oraz Papies (2016) w swoim badaniu dowodzą, iż wchodzące na rynek darmowe platformy streamingowe w znacznym stopniu przejęły popyt rynkowy na inne kanały dystrybucji muzyki (np. płyty CD). To samo badanie wykazało również, iż serwisy streamingowe swoim działaniem znacząco zwiększyły przychody na rynku muzycznym. Ponadto, nieograniczona możliwość konsumpcji twórczości także niszowych artystów doprowadziły do spadku znaczenia wydawnictw muzycznych w karierze artystów (Wlömert oraz Papies, 2016). Wikstrom (2009) twierdzi, iż w „nowej ekonomii muzyki” (ang. *New Music Economy*) wytwórnie muzyczne nie piastują już tak istotnej pozycji na rynku. Kluczową rolę odgrywają teraz artyści oraz ich managerowie (Haynes oraz Marshall, 2017). Potwierdza to również poniższa ilustracja prezentująca udział dużych wytwórni muzycznych w całkowitej ilości odtworzeń utworów na platformie Spotify.

Rys. 1. Udział dużych wydawnictw muzycznych w ogóle odtworzeń utworów na platformie Spotify



Źródło: Spotify Sec Filings

W rezultacie, nastąpiła znacząca dywersyfikacja preferencji konsumentów, które w poprzednim modelu dystrybucji muzyki skupione były wokół twórczości jedynie kilku, wcześniej odkrytych artystów (Wlömert oraz Papies, 2016). Ponadto, jak zostało wspomniane, szeroka oferta platform streamingowych pozwoliła na odkrywanie oraz konsumowanie twórczości również niszowych artystów. Datta, Knox oraz Bronnenberg

(2017) stwierdzili, iż większość konsumentów na ogół ceni sobie różnorodność słuchanej muzyki. Zatem wnioskować można, iż zgodnie z modelem Dixita-Stiglitz (1977) (wzór funkcji użyteczności poniżej) zwiększenie różnorodności dobra – w tym przypadku muzyki – prowadzić będzie do zwiększenia użyteczności z konsumpcji niniejszego dobra u konsumentów ceniących sobie różnorodność produktu (ang. *love for variety*). W rezultacie dojść można do konkluzji, iż digitalizacja branży muzycznej zwiększyła zadowolenie większości słuchaczy.

$$U = \left(\sum_{i=1}^N c_i^\rho \right)^{\frac{1}{\rho}} \quad \text{oraz} \quad \rho \in (0; 1)$$

gdzie:

- c_i - wielkość konsumpcji dobra i-tej odmiany
- ρ - zamiłowanie do różnorodności (ang. *love for variety*), czyli waga, jaką konsumenci przywiązują do różnorodności odmian dobra dostępnych na rynku
- U - użyteczność z konsumpcji dóbr

Jednakże, wyżej wymienieni badacze sformułowali swoje wnioski jeszcze na samym początku rozwoju platformy TikTok, przed okresem jej największej popularności. Warto nadmienić, iż grupa badawcza Vox (2022) określa TikTok’a jako swego rodzaju prekursora wyznaczającego nowe trendy muzyczne (ang. *trendsetter*) (niniejsze zagadnienie zostało szczegółowo opisane w rozdziale 3.2.) Zatem zasadne wydaje się stwierdzenie, że wzrost popularności serwisu TikTok mógł mieć również istotny wpływ na preferencje muzyczne użytkowników Spotify. Wzrost popularności platformy TikTok mógł być kolejnym etapem „mediamorfozy” branży muzycznej, który istotnie wpłynął na model konsumpcji muzyki. W konsekwencji, zasadna wydaje się być wątpliwość, czy w zaistniałych okolicznościach konsumenci nadal cenią sobie różnorodność oferowanej muzyki, czy może w wyniku wspomnianego zjawiska ich preferencje uległy ujednoliceniu. Pozostają również niepewności co do tego, czy wszystkie trendujące utwory są między sobą zróżnicowane oraz czy możliwe jest wyodrębnienie pewnych charakterystycznych atrybutów, które mogłyby stać za ich komercyjnym sukcesem, np. utwory aktualnie trendujące to tylko utwory taneczne czy pozytywne (idealnie wpasowują się w trendy obserwowane w serwisie TikTok). Należy

również zweryfikować aktualność wniosków wysnutych w poprzednim akapicie. Z tego powodu, w celu uzupełnienia powstałej luki badawczej, w przeprowadzanej analizie zdecydowano się na zawarcie hipotezy badawczej głoszącej, iż **istnieje heterogeniczność preferencji względem trendujących utworów muzycznych**.

1.2. Spotify jako globalny lider na rynku platform specjalizujących się w streamingu muzyki

Spotify to szwedzki serwis streamingowy oferujący swoim użytkownikom dostęp do nielimitowanej muzyki oraz podcastów. Wszystkie produkty oferowane przez platformę objęte są prawami autorskimi. Korzystanie z niniejszej aplikacji możliwe jest za pomocą licencji „freemium”, co oznacza że użytkownik może korzystać z serwisu po uprzedniej rejestracji i nie ponosi on żadnych dodatkowych opłat z tego tytułu, lub wykupując subskrypcję premium, która w kontraście do licencji „freemium”, zapewnia brak reklam, wyższą jakość muzyki, nielimitowaną liczbę pominięć utworów oraz wiele innych korzyści. Niezależnie od wybranego planu użytkowania, Spotify pozwala również na tworzenie, udostępnianie oraz odtwarzanie playlist utworów. Platforma konstruuje także wiele własnych muzycznych playlist, między innymi playlist prezentujących ranking najczęściej słuchanych utworów w danym okresie i/lub w danym obszarze (państwie, mieście).

W roku 2017 platforma Spotify zgromadziła ponad 100 milionów użytkowników, w tym 60 milionów użytkowników, którzy wykupili konto premium (Fleischer i Snickars, 2017). W roku 2024 było to już ponad 615 milionów użytkowników, w tym 239 milionów użytkowników korzystających z konta premium (Spotify, 2024). Jak stwierdza Hracs oraz Webster (2020), Spotify ukształtowało się jako lider wśród platform specjalizujących się w streamowaniu muzyki, pomimo, iż początkowo budżet niniejszej aplikacji był niewielki na tle innych firm (m.in. Apple, Amazon, Google), które także posiadały własne platformy służące do streamingu muzyki. Spotify jest jedną z największych spółek na oligopolistycznym rynku muzycznych serwisów streamingowych, generując około 27% przychodów niniejszego rynku (Tofalvy oraz Koltai, 2023). Taka sytuacja pozwala na określenie jej mianem jednej z obecnie wiodących platform streamingowych oraz skłania do refleksji nad czynnikami, które wyróżniają Spotify spośród innych platform o podobnym charakterze.

Jednym z takich komponentów może być trud włożony w zwiększanie lojalności swoich klientów. Hracs oraz Webster (2020) podkreślają, że użytkownicy platformy Spotify są

przywiązani i nie są skłonni do zmiany platformy na inną, ponieważ ich gust muzyczny został już rozpoznany i zaadaptowany na obecnej platformie. Natomiast zmiana platformy streamingowej oznaczałaby ponowną konieczność zaznajomienia się algorytmu z ich muzycznymi preferencjami. Warto nadmienić, że użytkownicy platformy Spotify szczególnie cenią ją za jej muzyczne rekomendacje tworzone na podstawie aktywności użytkownika (Hracs oraz Webster, 2020). Algorytmy rekomendacji utworów szybko rozpoznają preferencje poszczególnych użytkowników i na tej podstawie polecają precyzyjnie dalsze utwory muzyczne, które często cieszą się aprobatą odbiorców. Ruckenstein oraz Granroth (2020) twierdzą, że tak ukierunkowane rekomendacje mogą wywołać w użytkowniku „przyjemne uczucie bycia rozpoznanym” (ang. *„pleasurable feeling of recognition”*). Na tej podstawie można dojść do wniosku, że Spotify nie tylko pozwala na słuchanie muzyki, ale również słucha potrzeb swoich klientów.

Oprócz znakomitego algorytmu rekomendacji utworów, platforma oferuje także spersonalizowane podsumowania, takie jak „Spotify Wrapped” – w mowie potocznej często określane jako „muzyczne podsumowanie roku”. Jest to szereg informacji na temat muzycznych preferencji użytkownika, między innymi najczęściej słuchanych gatunków muzycznych, utworów, artystów czy czasu użytkowania niniejszej aplikacji. Wspomniana kampania pozwala na angażowanie konsumentów w działalność platformy. „Spotify Wrapped” jest jedną z najpopularniejszych, corocznych kampanii tworzonych przez niniejszy serwis (Swant, 2019). Jak podkreśla Swant (2019), jedną z jej kluczowych cech jest wygodny dla użytkownika format, w jaki prezentowane są dane na temat jego muzycznych preferencji w danym roku, oraz możliwość łatwego ich udostępnienia na innych platformach mediów społecznościowych (*social media*), głównie na Facebook’u oraz Instagram’ie. W roku 2019, ponad 60 milionów użytkowników zaangażowało się w powyższą kampanię (Swant, 2019).

Jak stwierdza Bonini oraz Gandini (2019), Spotify plasuje się na pozycji lidera w branży platform streamujących muzykę online. Platforma wyznacza nowe trendy w rozwoju serwisów muzycznych jak i systemów rekomendacji. Co więcej, serwis ten daje inspirację także innym sektorom branży rozrywkowej. Warto przytoczyć tutaj zjawisko określane przez Fleischer’a (2020) jako „spotification”, które opisuje postrzeganie platformy Spotify jako pewnego rodzaju model biznesowy. Wiele technologicznych start-up’ów stara się przenieść model działania platformy Spotify także na inne segmenty, tworząc swego rodzaju „Spotify dla książek” czy „Spotify dla filmów” (ang. *„Spotify for books”*, *„Spotify for movies”*) (Fleischer, 2020). „Spotification” odnosi się do dostosowania produktu w taki sposób, aby pod względem

interfejsu, funkcji, personalizacji, strategii marketingowych czy rekomendacji treści przypominał platformę Spotify. Należy nadmienić, że jest to tylko jedno z wielu znaczeń terminu „Spotification”, co wskazuje na ogromne znaczenie tej platformy na rynku (nie tylko muzycznym).

1.3. Rola Spotify w kształtowaniu dochodu artystów

W celu zrozumienia istoty platformy Spotify w działalności artysty, należy najpierw przyjrzeć się możliwym źródłom przychodu na rynku muzycznym. W dzisiejszym świecie źródła zarobków artysty na rynku muzycznym są znacząco zdywersyfikowane. Przeprowadzone analizy (Conolly oraz Krueger, 2006; Moreau oraz Bacache-Beauvallet, 2016) wskazują, iż do głównych źródeł można zaliczyć:


- koncerty oraz festiwale – zwykle artyści otrzymują 85% przychodów ze sprzedaży biletów (Fivelsdal, 2005). Należy jednak nadmienić, że ten procent może się zmieniać w czasie i zależeć od zdolności negocjacyjnych obu stron umowy
- sprzedaż płyt
- sprzedaż ubrań i gadżetów związanych z artystą (ang. *merchandise*)
- współprace reklamowe
- media społecznościowe (*social media*)
- tantiemy (ang. *royalty*)
- muzyczne platformy streamingowe

Niniejsze badanie szczególną uwagę kieruje w stronę platform streamingowych. Warto zaznaczyć, że większość serwisów streamingowych, w tym Spotify, nie praktykuje zawierania umów z indywidualnymi artystami, lecz z właścicielami praw autorskich do utworów (Cieślak, 2023). Wspomnianymi właścicielami praw autorskich mogą być między innymi wytwórnie czy też wydawcy muzyczni. Następnie, właściciele praw autorskich rozliczają się z indywidualnymi artystami na podstawie odrębnych umów (Cieślak, 2023). Dustee Jenkins (dyrektorka ds. Public Affairs Spotify) w wywiadzie dla „Rzeczpospolitej” (2023) wyjawia, iż tantiemy wypłacane są właścicielom praw autorskich w oparciu o statystykę „streamshare”, która oznacza udział artysty w całkowitej liczbie streamów na danym rynku. Natomiast pula tantiem dla danego kraju (ryнку) jest ściśle zależna od wysokości przychodów z subskrypcji oraz reklam. Jednakże, według Prey’a (2020) właściciele praw autorskich mogą liczyć na kwotę rzędu jedynie 50-54%

całkowitych przychodów netto jakie artysta wygenerował na platformie. Co więcej, Związek Artystów Wykonawców STOART wskazuje, iż „ponad 52 proc. polskich wykonawców nie otrzymało żadnego wynagrodzenia za streaming, a 26 proc. mniej niż równowartość 100 euro.” (Cieślak, 2023). Jak stwierdza Mühlbach, Saskia oraz Payal Arora (2020), to właśnie niskie wynagrodzenia artystów za ich osiągnięcia na platformie są głównym mankamentem działalności platform streamingowych.

Mimo relatywnie niskich przychodów, znamienita większość artystów decyduje się na współpracę z serwisem Spotify oraz innymi platformami o podobnym obszarze działalności. Muzyczne serwisy streamingowe odpowiadają za ponad połowę przychodów branży muzycznej na całym świecie oraz około 80% przychodów tej branży w Stanach Zjednoczonych (Federation of the Phonographic Industry, 2020; Recording Industry Association of America, 2019). Jednym z powodów ogromnego sukcesu platform streamingowych wśród artystów oraz słuchaczy może być fakt, iż nie jest to jedyna korzyść wypływająca z tej współpracy. Jak twierdzi Prey (2020), Spotify łączy w swojej działalności rynek muzyczny, marketingowy oraz finansowy. Dzieje się tak głównie za sprawą autorskich playlist tworzonych przez platformę, które dodatkowo promują utwory wśród użytkowników. Wielu artystów wybiera współpracę ze Spotify, również ze względu na jego dominację rynku platform streamingowych.

Rys. 2. Spotify jako połączenie trzech różnych rynków



Źródło: Opracowanie własne na podstawie: Prey, R. (2020). Locating Power in Platformization: Music Streaming Playlists and Curatorial Power. *Social Media + Society*, 6(2)

1.4. Znaczenie atrybutów utworu

Platforma Spotify wyróżnia szereg charakterystyk, którymi opisane są utwory muzyczne (ang. *song features*). Zaczynając od relatywnie obiektywnych cech, takich jak tonacja (ang. *key*), modus (ang. *mode*) czy tempo, aż po bardziej subiektywne, algorytmicznie wyliczane miary, takie jak taneczność (ang. *danceability*), akustyczność (ang. *acousticness*) czy pozytywność utworu określana przez zmienną „*valence*” (Askin oraz Mauskapf, 2017). Wspomniane charakterystyki stanowią podwaliny oraz fundamenty prężnie rozwijającej się dziedziny nauki o przebojach muzycznych, określanej jako „*Hit Song Science*” (HSS) (Oliveira i inni, 2022). Głównym celem przyświecającym HSS jest predykcja popularności utworu bazując na jego cechach, takich jak taneczność czy tempo. HSS jest także ściśle związane z obszarem „*Music Information Retrieval*” (MIR), który również analizuje dane muzyczne w celu zrozumienia struktury rynku muzycznego, wyestymowania matematycznego modelu predykcyjnego (zwykle wykorzystując techniki uczenia maszynowego) oraz zidentyfikowania cech utworu, które w sposób istotny przyczyniają się do zwiększenia jego potencjału na komercyjny sukces (Pachet, 2011). Jedną z najbardziej intrygujących kwestii, które stara się rozwiązać HSS, jest wyłonienie tych atrybutów utworu, które są istotne przy szacowaniu jego potencjału (ang. *hit potential*) spośród szerokiego wachlarza pozostałych charakterystyk, które mogą okazać się statystycznie nieistotnymi (Oliveira i inni, 2022).

HSS oraz MIR odgrywają kluczową rolę wśród platform specjalizujących się w streamowaniu muzyki (Montecchio, 2019). W kontekście Spotify, są one niezbędne przy tworzeniu spersonalizowanych rekomendacji muzycznych bazujących na głębokim uczeniu maszynowym (ang. *deep learning*) (Vall i inni, 2019). Ponadto, przewidywanie popularności utworów na podstawie ich cech jest szczególnie istotne dla firm mających na celu rozpoznanie preferencji swoich konsumentów i zwiększenie ich satysfakcji (Çimen oraz Kayis, 2021). MIR pomaga sprostać również oczekiwaniom użytkowników w kontekście odkrywania nowych utworów (Herremans i inni, 2014). Co więcej, Benetos, Ragano oraz Sgroi (2022) w swej publikacji dowodzą również, że pewne statystyki utworów, np. poziom pozytywności utworu (ang. *valence*), mogą służyć do odczytywania aktualnie panującego nastroju społecznego i zadowolenia z życia obywateli danego państwa (ang. *life satisfaction*). Natomiast Bulaj oraz Schriewer (2016) wskazują także na zastosowanie MIR w procesie terapeutycznym oraz w leczeniu chorób takich jak depresja czy choroba afektywna dwubiegunowa (ChAD).

ROZDZIAŁ II

Opis danych i metodologia badania

Rozdział zawiera szczegółowy opis baz danych wykorzystanych w badaniu oraz metodologii analizy. Przedstawiono próbę utworów muzycznych użytych w analizie, wskazując na ich cechy i kryteria selekcji. Niniejszy rozdział omawia również normalizację zmiennych i zastosowaną metodę klastrowania K-średnich, zapewniając szczegółowe informacje na temat metody wyboru liczby klastrów oraz analizy powstałych klastrów. Ponadto, opisane zostały również najważniejsze narzędzia statystyczne użyte podczas późniejszych rozważań. Uogólniona wizualizacja metodyki badania znajduje się w załączniku 1.

2.1. Bazy danych

W badaniu wykorzystano dwie bazy danych. Pierwsza z nich, służąca do przeprowadzenia klastrowania, zawiera utwory, które w latach 2020-2021 przynajmniej raz wystąpiły w zestawieniu „Top 200 Weekly (Global)” tworzonym przez platformę Spotify. Powyższe zestawienie aktualizowane jest co tydzień i zawiera najczęściej odtwarzane utwory na Spotify w danym tygodniu. Baza danych została oczyszczona z duplikatów i braków danych, w wyniku czego pozostało 1543 obserwacji. Za obserwację uznaje się utwór muzyczny. Spośród wielu zmiennych w bazie danych empirycznie wybrano te najistotniejsze dla niniejszego badania, które wymienione są w poniższej tabeli. Warto nadmienić, iż wszystkie wartości niżej wymienionych zmiennych generowane są algorytmicznie przez platformę Spotify. Niniejsza baza danych udostępniona została na platformie „Kaggle”².

Tabela 1. Opis zmiennych w bazie danych służącej do klastrowania

Nazwa zmiennej	Znaczenie	Rodzaj zmiennej oraz przyjmowane wartości
Streams	Ilość odtworzeń danego utworu	Zmienna ciągła przyjmująca wartość dowolnej liczby naturalnej
Danceability	Taneczność utworu, określa w jakim stopniu dany utwór jest taneczny	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]

² <https://www.kaggle.com/datasets/sashankpillai/spotify-top-200-charts-20202021> [Dostęp: 06.05.2024]

Energy	Określa w jakim stopniu dany utwór jest energiczny, intensywny w brzmieniu	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]
Speechiness	Opisuje ilość mowy/słów/wokalu w danym utworze	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]
Acousticness	Akustyczność, określa w jakim stopniu dany utwór jest akustyczny	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]
Liveness	Ukazuje poziom obecności widowni w nagraniu np. jeżeli zmienna Liveness przyjmuje wartości bliskie 1 to bardzo prawdopodobne jest, że ścieżka dźwiękowa utworu pochodzi z koncertu	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]
Tempo	Przybliżone tempo utworu wyrażone w liczbie uderzeń na minutę (ang. Beats Per Minute, BPM). Ukazuje „szybkość” danego utworu	Zmienna ciągła przyjmująca wartość dowolnej liczby naturalnej
Duration (ms)	Długość utworu w milisekundach	Zmienna ciągła przyjmująca wartość dowolnej liczby naturalnej
Valence	Poziom pozytywności utworu, w jakim stopniu utwór jest pozytywny. Utwory o wysokim indeksie Valence brzmią bardziej radośnie, o niższym - bardziej agresywnie, depresyjnie	Zmienna ciągła przyjmująca wartości z przedziału [0; 1]

Źródło: Opracowanie własne na podstawie Spotify API

Druga baza danych, zawierająca playlisty utworów stworzone przez użytkowników serwisu Spotify po oczyszczeniu z duplikatów oraz braków danych składała się na 11'013'847 obserwacji. Za obserwację uznaje się koniunkcję nazwy playlisty oraz zawartego w niej utwory muzycznego. W tym przypadku, aby obserwacja była uznana za duplikat musi posiadać dokładnie taki sam tytuł utworu, nazwę wykonawcy i tytuł playlisty. Wspomniana baza danych została udostępniona na stronie internetowej „Kaggle”³, gdzie nie zamieszczono informacji na temat zakresu gromadzonych danych. Z tego powodu, okres obserwacji wyżej wymienionej próbki nie jest znany. Spośród zmiennych występujących we wspomnianej bazie danych wybrano trzy najistotniejsze dla przeprowadzanej analizy – zmienną „trackname” oznaczającą tytuł utworu, zmienną „artistname” oznaczającą nazwę artysty

³ https://www.kaggle.com/datasets/andrewmvd/spotify-playlists?select=spotify_dataset.csv [Dostęp: 06.05.2024]

wykonującego dany utwór oraz zmienną „playlistname” oznaczającą nazwę playlisty stworzonej przez użytkownika. Próbką następnie została połączona z wcześniej opisaną próbką służącą do klastrowania poprzez scalenie (ang. *merge*) wykorzystując dopasowanie tytułu utworu oraz nazwy artysty między próbkami. W wyniku tego otrzymana baza danych dopuszczała występowanie obserwacji, które posiadają ten sam tytuł utworu oraz nazwę artysty, lecz różnią się nazwą playlisty. Tak stworzona baza danych została użyta do ocenienia liczebności występowania utworów z danego klastra w określonej playliście muzycznej. Innymi słowy, ocenienie ile utworów z danego klastra pojawia się w określonej playliście muzycznej.

2.2. Normalizacja zmiennych

Zmienne według których dokonano klastrowania to *Danceability*, *Energy*, *Speechiness*, *Acousticness*, *Liveness*, *Tempo*, *Duration (ms)* oraz *Valence*. Przed dokonaniem grupowania wyżej wymienione zmienne zostały wystandaryzowane, w celu ujednolicenia ich charakteru oraz ustabilizowania ich zmienności (Freyhult i inni, 2010). Zabieg ten jest stosowany powszechnie w przypadku segmentacji danych i jest szczególnie istotny, gdy stosowane są metody bazujące na miarach odległości między obserwacjami (Zhang oraz Gu, 2015). Zmienne były standaryzowane za pomocą poniższego wzoru (Chandrasekhar i inni, 2011):

$$z_i = \frac{x_i - \mu}{\sigma}$$

gdzie:

z_i	- obserwacja i-tej zmiennej po standaryzacji
x_i	- obserwacja i-tej zmiennej przed standaryzacją
μ	- średnia wartość obserwacji zmiennej przed standaryzacją
σ	- odchylenie standardowe wartości obserwacji zmiennej przed standaryzacją

2.3. Klastrowanie K-średnich

Klastrowanie metodą K-średnich (ang. *K-means clustering*) to jedna z najczęściej używanych metod analizy skupień, która dąży do przypisania n obserwacji do k klastrów (Jamnejad i inni, 2014). Jest ona szeroko używana ze względu na swoją wysoką efektywność oraz skalowalność przy analizowaniu dużych zbiorów danych (Kaur i inni, 2014). Do przeprowadzenia procedury klastrowania K-średnich zdecydowano się na użycie odległości euklidesowej. Algorytm grupowania metodą K-średnich może być opisany następującymi krokami (Wang i inni, 2011; Hartigan oraz Wong, 1979):

1. Ustalenie liczby skupień K
2. Wyznaczenie początkowego środka ciężkości dla każdego skupienia (znanych jako centroidy)
3. Przypisanie obiektów do skupień na podstawie ich odległości od centroidów
4. Wyznaczenie sumy odległości pomiędzy obserwacjami i centroidami w ramach klastrów
5. Optymalizacja prowadząca do ustalenia nowego środka skupień, aby zminimalizować sumę odległości z (4)
6. Powtórzenie kroków od 2 do 5, aż warunek zatrzymania (brak przesunięcia się centroidu) zostanie spełniony.

W celu oszacowania liczby skupień przeanalizowany został „Wykres łokcia” oraz wartości współczynnika Silhouette. Podczas sporządzenia „Wykresu łokcia” według poniższego wzoru wyliczana była wewnątrzgrupowa suma błędów kwadratowych (Within-Cluster-Sum of Squared Errors, WSS):

$$WSS = \sum_{k=1}^m \sum_{x_i, y_i \in C_k} ((x_i - x_k)^2 + (y_i - y_k)^2)$$

gdzie:

- | | |
|--------------|--|
| m | - ilość klastrów |
| (x_i, y_i) | - współrzędne i -tego punktu w k -tym klastrze |
| (x_k, y_k) | - współrzędne centroidu w k -tym klastrze |
| C_k | - k -ty klaster |

Natomiast do wyliczenia współczynnika Silhouette użyty został poniższy wzór:

$$\text{Współczynnik Silhouette} = \frac{b - a}{\max(a, b)}$$

gdzie:

- a - średni dystans między wszystkimi punktami w klastrze
- b - średni dystans między wszystkimi klastrami

2.4. Porównania wartości zmiennych w całej populacji oraz porównania parami

W celu zidentyfikowania zmiennych, które osiągają tę samą średnią wartość dla każdego klastra rozważano przeprowadzenie analizy wariancji ANOVA. Hipoteza zerowa testu ANOVA głosi, iż średnie we wszystkich wyodrębnionych populacjach są identyczne i równe. Ponadto, poprawne przeprowadzenie wspomnianego testu jest możliwe jedynie, gdy spełnione są jego założenia o homogeniczności wariancji oraz normalności rozkładu w wyodrębnionych grupach. Mając na uwadze weryfikację założenia o normalności rozkładu aplikowano test Jarque-Bera, którego hipoteza zerowa mówi o jednowymiarowej normalności badanej zmiennej losowej wobec alternatywnej hipotezy o braku występowania normalności rozkładu zmiennej. Statystyka testowa wspomnianego testu wyliczana była według następującego wzoru (Jarque oraz Bera, 1980):

$$JB = n \left[\frac{w}{6} + \frac{(k - 3)^2}{24} \right]$$

gdzie:

- JB - statystyka Jarque-Bera
- w - współczynnik skośności rozkładu
- k - współczynnik kurtozy rozkładu
- n - ilość obserwacji w próbie

Żadna zmienna nie posiadała rozkładu normalnego we wszystkich klastrach, zatem nie zostało spełnione jedno z założeń testu ANOVA. Tym samym, nie zostało również spełnione założenie testu Barletta służącego do badania homogeniczności wariancji (drugie z założeń testu ANOVA), który zakłada normalność rozkładu badanych populacji (Magiera, 2018). Finalnie, w badanych klastrach nie rozpoznano żadnych okoliczności w których założenia testu ANOVA byłyby spełnione. Zatem odstąpiono od aplikacji wspomnianego testu.

Alternatywnie do testu ANOVA przeprowadzono nieparametryczny test Kruskala-Wallisa, którego hipoteza zerowa mówi o równości median we wszystkich podgrupach wobec hipotezy alternatywnej głoszącej, iż nie wszystkie mediany są sobie równe. Statystyka testowa niniejszego testu wyliczana była według poniższego wzoru (Kruskal oraz Wallis, 1952):

$$T = \frac{12}{n(n+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(n+1)$$

gdzie:

- R_i - suma rang w i-tej grupie
- n_i - liczebność i-tej grupy
- n - łączna liczebność wszystkich grup

Natomiast w celu porównania cech klastrów parami stosowano nieparametryczny test Manna-Whitneya, którego hipoteza zerowa głosi, iż badane próby pochodzą z jednej populacji, która często określana jest również jako hipoteza zerowa o nieistotności różnic pomiędzy medianami badanych grup. W tym przypadku, statystyka testowa wyliczana była według poniższego wzoru (Mann oraz Whitney, 1947):

$$Z = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

gdzie:

$$U = R_1 - \frac{n_1(n_1+1)}{2}$$

- R_1 - suma rang elementów z pierwszej próby
- n_1, n_2 - liczebność odpowiednio pierwszej i drugiej próby

ROZDZIAŁ III

Badanie empiryczne

W niniejszym rozdziale zaprezentowano analizę klastrow utworów muzycznych wyodrębnionych na podstawie danych z platformy Spotify. Rozdział szczegółowo omawia metodologię wyboru liczby klastrow, z wykorzystaniem techniki „Wykresu łokcia” oraz współczynnika Silhouette. Kluczowym elementem rozdziału jest wykorzystanie metody klastrowania K-średnich do identyfikacji grup utworów, które charakteryzują się podobnymi cechami. Zastosowana jest również empiryczna charakterystyka klastrow opierająca się na analizie statystycznej, która uwzględnia rozkłady atrybutów muzycznych oraz kontekst wykorzystania utworów muzycznych przez użytkowników.

W dalszej części rozdziału przeprowadzono analizę cech utworów między klastrami, wykorzystując test Kruskala-Wallisa do oceny równości median, który potwierdził ich odpowiednie wyseparowanie. Dokonano również porównania charakterystyk klastrow parami między sobą oraz zidentyfikowano strukturę rynku. Badanie uwzględnia również analizę trendów muzycznych zwracając uwagę na rosnącą rolę platform cyfrowych, takich jak TikTok, w kształtowaniu się preferencji muzycznych.

Na koniec przedstawiono wnioski z przeprowadzonej analizy, potwierdzające zróżnicowanie preferencji słuchaczy oraz heterogeniczność trendów muzycznych wśród analizowanych utworów.

3.1. Klastrowanie

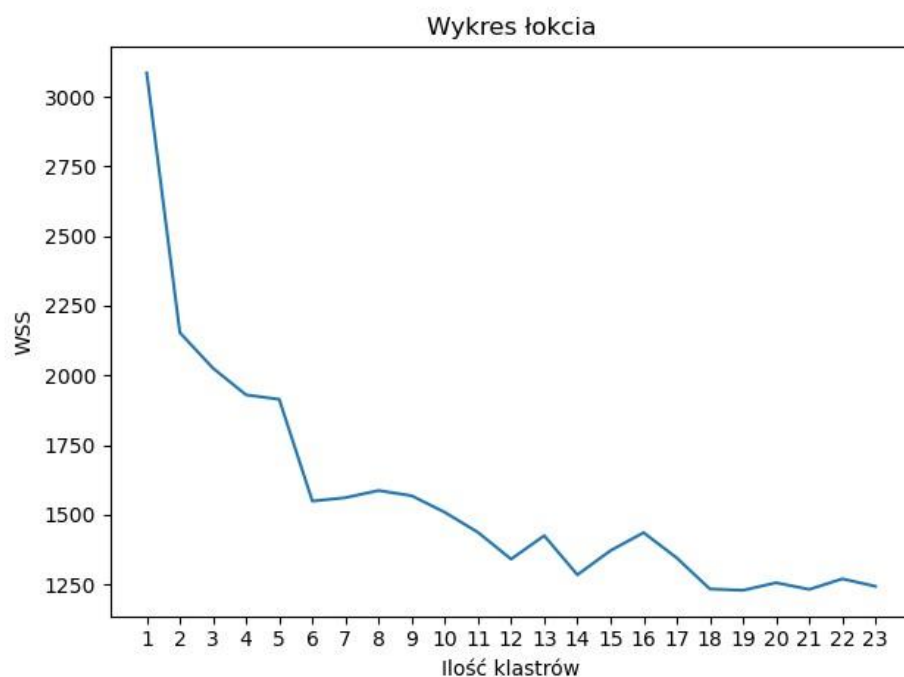
W celu grupowania obserwacji zdecydowano się na zastosowanie jednej z technik uczenia maszynowego – klastrowania K-średnich z wykorzystaniem metryki euklidesowej.

3.1.1. Wybór ilości klastrow

Na Rysunku 3. zaprezentowano tak zwany „Wykres łokcia”, który wraz z wyznaczonymi w Tabeli 2. wartościami współczynnika Silhouette, posłużył do wskazania liczby klastrow, na które powinna być podzielona wspomniana wcześniej baza danych utworów, które w latach 2020-2021 przynajmniej raz wystąpiły w zestawieniu „Top 200 Weekly (Global)” tworzonem przez serwis Spotify. Na osi pionowej „Wykresu łokcia”

odłożona została wewnątrzgrupowa suma błędów kwadratowych (*Within-Cluster-Sum of Squared Errors, WSS*), natomiast na osi poziomej zaprezentowano kolejne ilości klastrow. Zgodnie z teorią, wartość WSS będzie radykalnie spadać, gdy uzyskany zostanie nowy homogeniczny klaster. Analogicznie, gdy klastry homogeniczne będą nieefektywnie dzielone na mniejsze grupy to spadek wartości WSS będzie relatywnie mniejszy. Wskutek tego ekspercko uznano, że optymalna ilość klastrow dla tego zbioru danych równa jest 6, z ewentualnym rozważeniem zastosowania ilości 5 klastrow. Jednakże, biorąc również pod uwagę wartości współczynnika Silhouette stwierdzono, iż najbardziej efektywnym rozwiązaniem będzie zastosowanie podziału na 5 klastrow, ze względu na relatywnie duży spadek wartości wspomnianego współczynnika podczas przejścia z ilości 5 do ilości 6 klastrow.

Rys. 3. Wykres łokcia



Źródło: Opracowanie własne

Tabela 2. Wartości współczynnika Silhouette dla poszczególnych ilości klastrow


Ilość klastrow	Wartość współczynnika Silhouette
2	0.2503
3	0.1547
4	0.1335
5	0.1392
6	0.1288
7	0.1248
8	0.1256
9	0.1226

Źródło: Opracowanie własne

3.1.2. Analiza struktury klastrow

W wyniku klastrowania uzyskano 5 grup (numerowanych kolejno od 0 do 4), których udział procentowy w całości wraz z umieszczonymi poniżej liczebnościami zostały zaprezentowane na Rysunku 4. Niniejsza wizualizacja jednoznacznie wskazuje na znaczącą różnicę w liczebnościach klastrow. Klastry „0” oraz „1” są grupami najliczniejszymi i łącznie stanowią ponad połowę liczebności całej populacji. Podczas gdy najmniej liczny klaster „4” posiada relatywnie niską licznosc wynoszącą zaledwie 6%.

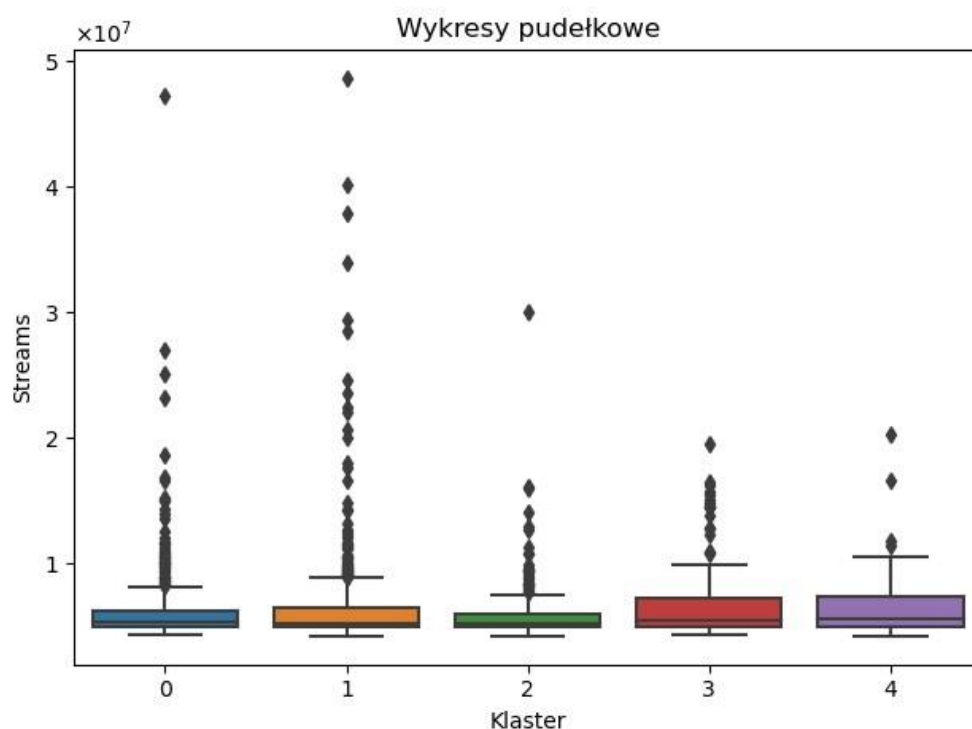
Rys. 4. Struktura klastrow



Źródło: Opracowanie własne

W toku analizy wykonano także wykresy pudełkowe (Rysunek 5.) w podziale na ustalone wcześniej klastry. Na osi pionowej odłożono zmienną „Streams” oznaczającą liczbę odtworzeń utworu w serwisie Spotify. Wspomniany diagram wskazuje na dużą liczbę obserwacji odstających w niemal każdym klastrze. Jednakże, w wyniku dalszej analizy wykazano, iż maksymalny udział obserwacji odstających w klastrze wynosi około 12%. Ostatecznie nie zdecydowano się na usunięcie, bądź przekształcenie obserwacji odstających. Ponadto, na podstawie wspomnianego wykresu stwierdzono występowanie prawostronnej asymetrii rozkładu we wszystkich klastrach, co jest zgodne z logiką badania, ponieważ baza danych zawiera jedyne utwory najczęściej odtwarzane – istnieje pewien dolny próg odcięcia, ponieważ w próbie nie występują utwory z relatywnie małą liczbą odtworzeń. Co więcej, klastry są zróżnicowane pod względem wielkości rozstępu międzykwartylowego – największy rozstęp międzykwartylowy występuje w klastrach „4” oraz „3”, natomiast najmniejszy w klastrze „2”. Dodatkowo, wartości median w klastrach oscylują wokół niemalże tej samej wartości. Zatem stwierdzono zasadność weryfikacji hipotezy o równości średnich we wszystkich podpróbach (klastrach). W tym celu rozważano przeprowadzenie analizy wariancji ANOVA. Jednakże, przed przystąpieniem do wspomnianej analizy zweryfikowano jej założenia. W tym celu wykonano test statystyczny Jarque-Bera dla którego otrzymano wartości p-value bliskie 0 w każdym z klastrów oraz stwierdzono odrzucenie hipotezy zerowej mówiącej o normalności rozkładu dla przyjętego poziomu istotności równego 5%. Zatem biorąc pod uwagę wyniki testu Jarque-Bera oraz zauważoną na wykresach pudełkowych (Rysunek 5.) prawostronną asymetrię rozkładu, wykryto brak występowania rozkładu normalnego zmiennej „Streams” w klastrach, co skutkowało niespełnieniem jednego z założeń testu ANOVA oraz niemożnością wykonania tego testu. Alternatywnie, postanowiono przeprowadzić nieparametryczny test Kruskala-Wallisa, którego hipoteza zerowa mówi o równości median we wszystkich podgrupach. Test Kruskala-Wallisa składa się na przeprowadzenie mechanizmu wielokrotnych porównań, zatem w celu przeciwdziałania problemowi wielokrotnych porównań zdecydowano się na przyjęty poziom istotności (5%) poprawkę Bonferroniego. W wyniku czego uzyskano poziom istotności równy 0,5%. Test Kruskala-Wallisa przeprowadzony dla zmiennej „Streams” wykazał p-value na poziomie około 0,9% które okazało się być wyższe od przyjętego poziomu istotności z korektą Bonferroniego, co pozwoliło na przyjęcie hipotezy zerowej testu. Zatem mediana liczby odtworzeń jest równa we wszystkich klastrach.

Rys. 5. Wykresy pudełkowe klastrów



Źródło: Opracowanie własne

3.1.3. Empiryczna charakterystyka klastrów

Każdemu z klastrów nadano jego empiryczną charakterystykę w oparciu o średnie wartości cech utworów w całej populacji (Załącznik 3) oraz w podziale na poszczególne klastry (Załącznik 2). Klaster „0” posiada najniższą średnią wartość parametru *Valence* (0,33) oraz relatywnie niską średnią wartość dla parametru *Danceability* (0,64). Podczas, gdy średnia wartość parametru *Valence* dla całej populacji wynosi 0,51, natomiast w przypadku parametru *Danceability* wynosi ona 0,69. W konsekwencji, klaster „0” określony został jako zbiór melancholijnych utworów muzycznych, wyraźnie wyrażających smutek oraz nienadających się do tańczenia. Zaś klaster „1” charakteryzuje się najwyższą średnią wartością zmiennej *Valence* (0,71) oraz *Energy* (0,73) spośród wszystkich klastrów. Ponadto, wykazuje on relatywnie wysoką wartość zmiennej *Danceability* (0,75) w porównaniu do wcześniej wymienionej wartości średniej zmiennej *Danceability* dla całej populacji. W wyniku tego stwierdzono, iż klaster „1” charakteryzuje się wyjątkową energicznością i pozytywnym nacechowaniem, stanowiąc swoisty kontrpunkt w kontekście taneczności do innych klastrów z pominięciem klastra „2”. Klaster 2 wyróżnia się najwyższym średnim

poziomem zmiennej *Danceability* (0,77) na tle pozostałych klastrów. Co więcej, posiada on również najwyższą średnią wartość zmiennej *Tempo* (129,73) oraz *Speechiness* (0,29). Wszystkie wspomniane wartości w sposób znaczący przewyższają średnie wartości cech utworów dla całej populacji. W efekcie sformułowano wniosek, że klaster „2” wyróżnia się nadzwyczajną tanecznością oraz obfitością tekstów i wypowiedzi werbalnych, manifestując prędkość i intensywność charakterystyczną dla gatunku muzycznego, jakim jest rap oraz hip-hop. W dalszej kolejności ustalono, że klaster „3” posiada najniższe średnie wartości wśród wszystkich klastrów dla zmiennych *Danceability* (0,55), *Energy* (0,38), *Speechiness* (0,06) oraz *Tempo* (115,46). Wszystkie te wartości w sposób znaczny różnią się od średnich wartości parametrów wyznaczanych dla całej próbki. Dodatkowo, klaster ten cechuje się relatywnie niską średnią wartością parametru *Valence* (0,38). Na tej podstawie uznano, że klaster „3” zawiera w sobie utwory określane jako akustyczne. Jednocześnie, charakteryzujące się on relatywnie smutnym tonem, przejawiającym się w niskim tempie oraz braku energetyzującego aspektu, co skutkuje nietanecznym i nieenergicznym charakterem utworów. Wreszcie klaster „4”, który posiada najwyższą spośród wszystkich klastrów średnią wartość zmiennej *Energy* (0,73) oraz *Liveness* (0,61). Warto nadmienić, iż w tym przypadku, wartość dla zmiennej *Liveness* jest rekordowo wysoka na tle średnich wartości tej zmiennej w pozostałych klastrach (oscylują one wokół wartości 0,15). Finalnie stwierdzono, że klaster „4” posiada wyjątkowo energiczny charakter, który jednak nie wiąże się z tanecznością, lecz jest wynikiem znaczącego uczestnictwa publiczności, co sugeruje występowanie zapisów koncertowych w tym klastrze.

Tabela 3. Największa ilość wystąpień utworów w playlistach według klastrów

Klaster	Tytuł playlisty	Liczba wystąpień utworów w playliście
0	<i>Starred</i>	19
	<i>Liked from Radio</i>	18
	<i>Chill</i>	13
	<i>Favoritas de la radio</i>	12
	<i>Random</i>	11
	<i>nice</i>	11
	<i>My Shazam Tracks</i>	10
	<i>Indie</i>	9
1	<i>Starred</i>	22
	<i>Liked from Radio</i>	17
	<i>Christmas</i>	11
	<i>Party</i>	11

1	<i>Favoritas de la radio</i>	9
	<i>christmas</i>	9
	<i>Running</i>	8
	<i>workout</i>	8
	<i>Workout</i>	7
2	<i>Rap</i>	2
	<i>Starred</i>	2
	<i>Hip-Hop</i>	2
	<i>Running</i>	2
3	<i>Starred</i>	21
	<i>Liked from Radio</i>	16
	<i>Christmas</i>	15
	<i>xmas</i>	11
	<i>xmas</i>	11
	<i>Jul</i>	10
	<i>Christmas !</i>	9
	<i>Christmas Playlist</i>	9
	<i>Chill</i>	9
	<i>Favoritas de la radio</i>	9
	<i>Christmas 2014</i>	9
4	<i>Starred</i>	6
	<i>Liked from Radio</i>	5
	<i>Mix</i>	4
	<i>Rock</i>	4
	<i>Favoritas de la radio</i>	3

Źródło: Opracowanie własne

Ponadto, w wyniku łączenia obu wykorzystywanych baz danych, dotyczących parametrów utworów i playlist utworów stworzonych przez użytkowników serwisu Spotify (proces łączenia baz danych został opisany w rozdziale 2.1.) uzyskano potwierdzenie większości empirycznych cech nadanych odpowiednim klastrom w poprzednim akapicie (Tabela 3.). Najliczniejszy klaster „0” w rzeczywistości zawiera tytuły playlist wskazujące na jego melancholijny charakter (*Chill, Nice, Indie*). Natomiast utwory muzyczne z klastra „1” często zawierają się w playlistach przeznaczonych do uprawiania sportu, aktywności fizycznej czy zabawy (*Party, Running, Workout, Christmas*), co dodatkowo poświadcza o wysokiej taneczności oraz energiczności utworów znajdujących się w tym klastrze. Niniejsza analiza upewniła również o wcześniejszym przypuszczeniu jakoby klaster „2” zawierał utwory z gatunku hip-hop lub rap. Biorąc pod rozważania klaster „3” potwierdzono jego melancholijny, mało energiczny oraz spokojny ton, który również cechuje playlisty utworów świątecznych (*Christmas, Xmas, Xmas, Christmas !*). Klaster „4” okazał się być bardzo zróżnicowany pod względem tytułów playlist, zatem niniejsza analiza nie pozwoliła na

jednoznaczne potwierdzenie empirycznego charakteru tego klastra. Co więcej, jednym z najbardziej interesujących aspektów analizy jest zaobserwowane zjawisko częstego występowania playlist zatytułowanych w sposób sugerujący iż są one zbiorem utworów, które zostały wcześniej odkryte i usłyszane na innych platformach, takich jak radio czy serwis Shazam. Ten fakt może wskazywać na nie tylko istnienie zaobserwowanego przez grupę Vox (2022) zjawiska „TikTok-to-Spotify pipeline”, ale także potencjalnych, analogicznie działających zjawisk, które określić można jako „Radio-to-Spotify pipeline” czy też „Shazam-to-Spotify pipeline”. Wskazane jest zatem dalsze badanie tego zjawiska w celu pełniejszego zrozumienia. W związku z tym, w następnym rozdziale postanowiono przeprowadzić szczegółową analizę zjawiska „TikTok-to-Spotify pipeline”, w celu weryfikacji jego rzeczywistego istnienia.

3.2. Zjawisko „TikTok-to-Spotify pipeline”


Pojęcie „TikTok-to-Spotify pipeline” po raz pierwszy użyte zostało w badaniu przeprowadzonym przez grupę „Vox” w 2022 roku (Vox, 2022). Niniejsze zjawisko to swego rodzaju połączenie między aktualnie trendującym (ang. *viral*) utworem na platformie TikTok, a muzycznym sukcesem autora wspomnianego utworu w serwisie Spotify. Zjawisko opisuje sytuację, w której użytkownik TikTok’a odkrywa całkowicie nowy dla niego utwór, a następnie przenosi się na platformę Spotify, gdzie słucha jego pełnej wersji i poznaje pozostałą twórczość artysty. Innymi słowy, zjawisko to można zdefiniować jako przepływ użytkowników TikTok’a na platformę Spotify w celu odnalezienia utworu, który właśnie usłyszeli. W ten sposób użytkownicy TikTok’a generują kolejne wyświetlenia utworów na platformie Spotify, a tym samym wpływają na zwiększenie popularności danego artysty (jak i jego utworów) w serwisie Spotify. TikTok jako swego rodzaju prekursor wyznacza nowe trendy muzyczne (ang. *trendsetter*), które następnie przenoszą się do serwisu Spotify.

3.2.1. Teoretyczne uzasadnienie

Badacze grupy „Vox” w swojej pracy potwierdzają występowanie zjawiska „TikTok-to-Spotify pipeline” na przykładzie artysty znanego jako „JVKE”. Utwór stworzony przez JVKE’a szybko stał się *viralem* na platformie TikTok, co spowodowało wzrost miesięcznej liczby słuchaczy artysty z zaledwie 1 000 do około 3.4 miliona w ciągu jedynie 3 miesięcy (Vox,

2022). Sukces na platformie TikTok okazał się mieć permanentny wpływ na popularność wspomnianego artysty w serwisie Spotify, co prezentuje poniższa ilustracja. W kolejnym badaniu, działacze grupy „Vox” dowodzą, iż 25% artystów notowanych w zestawieniach najpopularniejszych utworów w serwisie Spotify pochodzi z TikTok’a, a przed pojawienie się na platformie TikTok, nie posiadali oni dużej ilości słuchaczy czy też ogólnej rozpoznawalności (Vox, brak daty).

Rys. 6. Wpływ zjawiska „TikTok-to-Spotify pipeline” na ilość słuchaczy artysty „JVKE”



Źródło: <https://www.youtube.com/watch?v=S1m-KgEpoow&t=1s>

Co więcej, możliwość występowania tego rodzaju zjawiska potwierdza również teoria ekonomii, która wskazuje, iż konsumenci często kierują się trendami przy podejmowaniu decyzji zakupowych, w tym wyborze muzycznych preferencji (Lee oraz Chen, 2021). Ponadto, występowania zjawiska „TikTok-to-Spotify pipeline” uwierzytelnia również powszechnie rozwijające się zjawisko FOMO (ang. *Fear of missing out*). Przybylski i inni (2013) definiują zjawisko FOMO jako „wszechogarniający lęk, że inne osoby w danym momencie przeżywają bardzo satysfakcjonujące doświadczenia, w których ja nie uczestniczę”. W wyniku tego, zasadne wydaje się występowanie potencjalnego pociągu konsumentów do podążania za obecnie obowiązującymi muzycznymi trendami w obawie przed ich przegapieniem oraz kreowanie na ich podstawie własnych preferencji muzycznych. Syndrom FOMO często określa się jako chorobę cywilizacyjną. Jaworska oraz Sekścińska (2022) dowodzą w swym badaniu, iż wysoki poziom FOMO może powodować ogólne pogorszenie się nastroju, a nawet depresję (Oberst i inni, 2016) czy alkoholizm (Riordan i inni, 2015). Badania wskazują (Jupowicz-Ginalska i inni,

2019), że 14% polskich internautów posiada wysoki poziom FOMO, a 67% badanych cechuje się średnim poziomem FOMO. Natomiast, aż 94% osób w 15-19 lat doświadcza syndromu FOMO o średnim lub wysokim poziomie nasilenia (Jupowicz-Ginalska i inni, 2019). Choć syndrom FOMO jest charakterystyczny głównie dla wcześniej wspomnianych cyfrowych tubylców (ang. *digital natives*), to występuje on również często wśród osób określanych jako „*digital immigrants*” (Rahmadania, 2023), czyli osób które dorastały przed rozpoczęciem się ery cyfryzacji. Powyższe statystyki, ukazują ogromną skalę występowania syndromu FOMO oraz jego potencjalnej wagi przy dalszym badaniu zjawiska „TikTok-to-Spotify pipeline”.

Również Ole Obermann (Global Head of Music, TikTok) stwierdza, że „TikTok stał się integralną częścią odkrywania muzyki, łącząc artystów z ich fanami [...]”, a ponadto dodaje, że „TikTok jest domem dla trendów muzycznych, które przenikają branżę, listy przebojów oraz kulturę.” (TikTok, 2021). 75% użytkowników TikTok’a deklaruje, że odkrywają oni nowych artystów za pomocą tej platformy, a 63% użytkowników TikTok’a usłyszało na nim utwór, którego wcześniej nie znali (MRC Data, 2020). Co więcej, 67% użytkowników, którzy usłyszeli wcześniej nieznaną utwór na TikTok’u, poszukuje go następnie na różnych muzycznych platformach streamingowych (MRC Data, 2020).

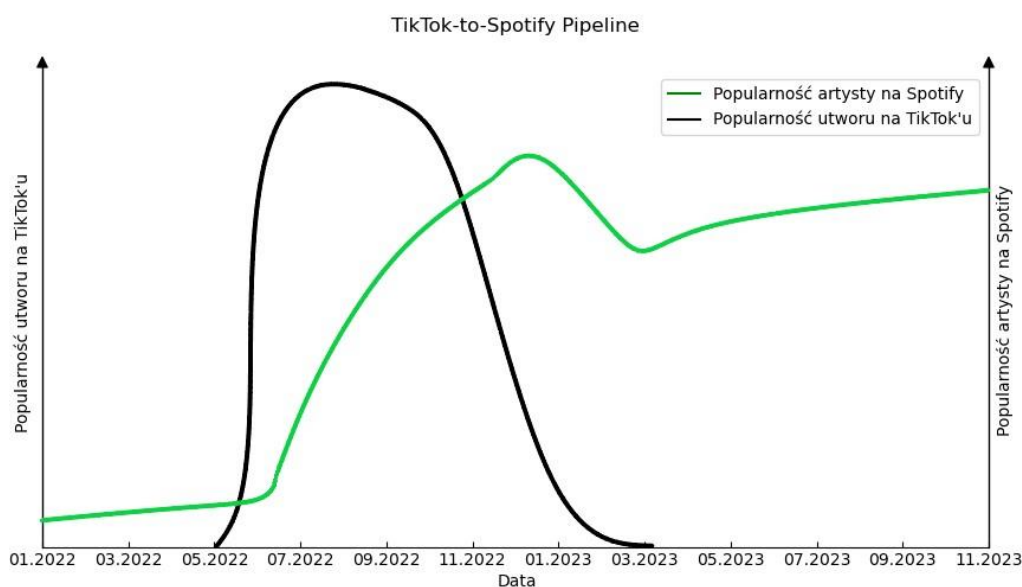
Wszystkie wyżej przytoczone aspekty wydają się jednoznacznie wskazywać na rzeczywiste zaistnienie zjawiska „TikTok-to-Spotify pipeline”, co stanowi motywację do jego dalszej, empirycznej analizy.

3.2.2. Empiryczne badanie zjawiska

W wyniku wyżej wskazanej, teoretycznej zasadności występowania zjawiska „TikTok-to-Spotify pipeline” zdecydowano się zweryfikować ten proces również empirycznie. Jednakże, badanie zostało przerwane już na poziomie gromadzenia danych, ponieważ po wnikliwej analizie ogólnodostępnych baz danych stwierdzono brak odpowiedniej ilości oraz jakości danych niezbędnych do przeprowadzenia analizy. Mimo to, w trakcie badania sformułowano pierwsze kierunki potencjalnej analizy, które w uogólniony sposób zaprezentowano na poniższym rysunku. Stwierdzono, iż rozkład zmiennej określającej popularność danego utworu na platformie TikTok będzie cechować się prawostronną asymptotycznością, która winna jest powstać w wyniku powolnego wygaszania się trendu, a tym samym spadku popularności utworu na platformie TikTok. Ponadto, z racji wysokiej dynamiki występowania i wygaszania się trendów na TikTok’u, funkcja ta powinna być relatywnie bardziej ograniczona na osi X, niż

funkcja reprezentująca poziom popularności danego artysty w serwisie Spotify. Ponadto, zasugerowano również, iż w przypadku dalszej analizy wydaje się być zasadna próba aproksymacji rozkładu zmiennej oznaczającej popularność artysty w serwisie Spotify za pomocą dystrybuanty rozkładu Weibulla. Podejrzewa się, iż największym istotnym odstępstwem rozkładu empirycznego od teoretycznej dystrybuanty rozkładu Weibulla może być moment spadku popularności artysty w serwisie Spotify (na poniższym rysunku znajduje się on w okolicach roku 2023), gdyż dystrybuanta rozkładu Weibulla prezentuje nieujemne nachylenie dla każdej wartości. Powyższe stwierdzenia wysnuto na podstawie Rysunku 6 (sukces artysty „JVKE”) oraz raportu grupy Vox (brak daty) z których wynika, iż początkowo popularność danego artysty w serwisie Spotify stopniowo rośnie, lecz w momencie kształtowania się trendu na platformie TikTok z wykorzystaniem danego utworu wspomnianego artysty – jego popularność wzrasta w relatywnie wyższym tempie. Następnie, po osiągnięciu maksimum popularności utworu na TikToku (ang. *virality peak*) oraz po osiągnięciu maksimum popularności artysty w serwisie Spotify, wielkość tej zmiennej spada, aby ponownie wrócić do stabilnego, relatywnie niskiego wzrostu sprzed swego rodzaju „szoku” spowodowanego znalezieniem się utworu wśród trendów muzycznych. Funkcja dla serwisu Spotify powinna zawierać w sobie również opóźnienie względem funkcji dla platformy TikTok, ze uwagi na czas potrzebny do przeniesienia się trendu między wspomnianymi platformami.

Rys. 7. Przypuszczalna postać zjawiska „TikTok-to-Spotify pipeline”



Źródło: Opracowanie własne

Należy również nadmienić, iż powyższe rekomendacje należy rozważać jedynie w kontekście występowania zjawiska „TikTok-to-Spotify pipeline”. Oznacza to w szczególności, że wcześniej wspomniane sugestie mogą nie być zasadne w przypadku utworów, które nie były „*viralem*” w serwisie TikTok.

Na tym etapie postanowiono przerwać analizę zjawiska „TikTok-to-Spotify pipeline” oraz powrócono ponownie do głównego nurtu niniejszej pracy, w celu weryfikacji postawionej hipotezy oraz rozpoznania aktualnej struktury rynku muzycznego.

3.3. Analiza cech utworów między klastrami

W podrozdziale rozdziale 3.1.3. wykazano istotne różnice między klastrami w kontekście empirycznych charakterystyk, które zostały im nadane. W celu statystycznej weryfikacji tych różnic i wyodrębnienia potencjalnych cech wspólnych między klastrami, zdecydowano się na przeprowadzenie dalszej analizy statystycznej.

3.3.1. Porównanie cech utworów we wszystkich klastrach

W celu zweryfikowania czy występuje taka cecha utworu, która posiada tę samą wartość we wszystkich klastrach, ponownie postanowiono przystąpić do weryfikacji założeń testu ANOVA w celu jego późniejszego przeprowadzenia. Aby zaistniała możliwość zastosowania wspomnianego testu jednorodności wielu średnich ANOVA na danej cesze utworu, wymagane było wystąpienie rozkładu normalnego oraz równości wariancji dla danej cechy we wszystkich klastrach. W tym celu przeprowadzono testy Jarque-Bera (hipoteza zerowa mówiąca o normalności rozkładu badanej zmiennej) dla rozkładu każdej cechy w każdym klastrze. Wyniki wyżej wymienionego testu wskazały na brak spełnienia założenia o normalności rozkładu zmiennej, co skutkowało w wykazaniu braku możliwości przeprowadzenia testu ANOVA. Z tego powodu, zdecydowano się na ponowne zastosowanie nieparametrycznego testu Kruskala-Wallisa, którego hipoteza zerowa mówi o równości median we wszystkich podgrupach. Po raz kolejny zastosowano również korektę Bonferroniego w celu minimalizacji problemu porównań wielokrotnych oraz zapewnienia kontroli błędu I rodzaju. W ten sposób otrzymano poziom istotności równy 0,5%. Test Kruskala-Wallisa przeprowadzono dla każdej cechy utworu w podziale na klastry i uzyskano wyniki p-value mniejsze od 0,5%. Zatem, dla przyjętego poziomu istotności z poprawką

Bonferroniego odrzucono hipotezę zerową dla każdej cechy utworu, co oznacza, iż mediany charakterystyk utworów nie są równe między klastrami. Dowodzi to, że klastry zostały odpowiednio wyseparowane, zapewniając heterogeniczność między grupami.

3.3.2. Porównanie cech klastrow parami

W poprzednim podrozdziale dowiedziono iż charakterystyki utworów nie są równe między klastrami, co gwarantuje zróżnicowanie między nimi. Zatem w celu rozpoznania struktury analizowanej próbki utworów muzycznych i zweryfikowanie podobieństw między klastrami zdecydowano się na porównanie cech klastrow parami. Rozkład charakterystyk poszczególnych klastrow cechuje się w znamienitej większości brakiem występowania rozkładu normalnego oraz znacznymi różnicami w liczebnościach klastrow. Z tego powodu zdecydowano się na zastosowanie nieparametrycznej procedury rang Manna-Whitneya, która nie zakłada wspomnianych wcześniej właściwości podgrup. W trakcie niniejszej analizy ujawniono przypadki dla których wartość p-value dla wspomnianego testu przekroczyła przyjęty poziom istotności 5% (Tabela 4.), a zatem w tych okolicznościach przyjmowano hipotezę zerową mówiącą o tym, że badane próby pochodzą z jednej populacji, która często określana jest również jako hipoteza zerowa o nieistotności różnic pomiędzy medianami badanych grup. Następnie, w przypadku przyjęcia hipotezy zerowej, sumowane były liczebności konkretnych klastrow w podziale na cechy utworów. W ten sposób ustalono, iż utwory o relatywnie wysokim poziomie melancholii stanowią około 39,66% ogółu utworów - stanowi to uzupełnienie badania Razy oraz Krishnadas'a (2020), którzy w swoim modelu wskazują jedynie statystykę oznaczającą poziom pozytywności utworu (ang. *valence*) jako statystycznie istotną. Z kolei Kim oraz Oh (2021) uznali energiczność utworu jako istotną w kontekście analizy trendujących utworów, natomiast Reiman oraz Örnell (2018) dostrzegli, iż niniejsza charakterystyka stopniowo zwiększa się wraz z każdą dekadą. O poprawności wyżej wskazanych wniosków dowodzą również wyniki niniejszego badania, które wykazują, iż utwory o bardzo wyrazistym charakterze energicznym reprezentują aż około 40,31% wszystkich utworów zawartych w próbce. Podczas gdy kompozycje o skrajnie długim czasie trwania stanowią około 45,69% zbioru najpopularniejszych utworów, co stoi w opozycji do wniosku wysnutego przez Nijkamp'a (2018) dowodzącego w swej pracy o negatywnej korelacji między długością trwania utworu, a jego liczbą odtworzeń.

Tabela 4. Wartości p-value przekraczające przyjęty poziom istotności (5%) podczas stosowania procedury Manna-Whitneya

Zmienna	Badane klastry		p-value
Acousticness	0	1	0,81
	2	4	0,08
	1	4	0,22
	0	2	0,61
	1	2	0,45
	0	4	0,16
Danceability	0	4	0,71
Duration (ms)	1	4	0,36
	1	3	0,3
	0	4	0,59
	0	3	0,41
	3	4	0,93
Energy	0	2	0,71
	1	4	0,97
Liveness	0	2	0,65
	1	2	0,79
	1	3	0,67
	2	3	0,39
	0	1	0,36
	0	3	0,15
Tempo	0	4	0,71
	3	4	0,09
Tempo	1	4	0,57
	0	1	0,15
Valence	0	3	0,052
	2	4	0,35

Źródło: Opracowanie własne

3.4. Walidacja wyników analizy

W celu walidacji empirycznych charakterystyk klastrów oraz zagwarantowania ich homogeniczności wewnątrz klastra zdecydowano się na wyliczenie współczynnika Giniego. W ten sposób zweryfikowano, czy średnie wartości zmiennych, na podstawie których klastry były charakteryzowane, nie są zaburzane przez wartości skrajne, co znacząco pogorszyłoby wyniki i wnioskowanie z badania. Wartości współczynnika Giniego były bliskie wartości 0 dla większości zmiennych w klastrach. Jednak, szczególną uwagę zwrócono na wartości wspomnianego współczynnika dla zmiennej „Streams” oraz zmiennych w poszczególnych klastrach, na podstawie których wnioskowano w rozdziale 3.2.2.. W kontekście tych

zmiennych wartości współczynnika Giniego były relatywnie niskie, co gwarantuje poprawność otrzymanych wyników, wnioskowania oraz heterogeniczność między klastrami, a homogeniczność wewnątrz klastrów. Szczegółowe wyniki wspomnianej analizy zaprezentowane są w poniższych tabelach.

Tabela 5. Wartości współczynnika Giniego w podziale na klastry

Klaster	Średnia wartość współczynnik Giniego dla całego klastra
0	0,17
1	0,15
2	0,15
3	0,16
4	0,17

Źródło: Opracowanie własne

Tabela 6. Wartości współczynnika Giniego dla wybranych zmiennych oraz klastrów

Klaster	Zmienna	Współczynnik Giniego
0	<i>Streams</i>	0
	<i>Duration</i>	0,11
	<i>Valence</i>	0,24
1	<i>Streams</i>	0
	<i>Energy</i>	0,09
2	<i>Streams</i>	0
3	<i>Streams</i>	0,01
	<i>Duration</i>	0,16
	<i>Valence</i>	0,31
4	<i>Streams</i>	0,02
	<i>Duration</i>	0,15
	<i>Energy</i>	0,11

Źródło: Opracowanie własne

3.5. Wnioski z przeprowadzonej analizy

Wyniki przeprowadzonego badania wydają się potwierdzać postawioną hipotezę o heterogeniczności preferencji konsumentów względem trendujących utworów muzycznych. Zastosowanie techniki klastrowania metodą K-średnich pozwoliło na wyseparowanie 5 klastrów, które okazują się być homogeniczne wewnątrz oraz heterogeniczne między sobą. Wykazano istotne różnice w charakterystykach utworów między klastrami, które jednak nie

przekładają się na statystycznie istotne różnice w wysokości mediany liczby odtworzeń dla danego klastra. Ponadto, sama wykonalność procesu klastrowania, w wyniku którego powstały satysfakcjonujące oraz wiarygodne wyniki, wskazuje na zaistniałe zróżnicowanie atrybutów najpopularniejszych utworów. W wyniku powyższego, przyjęto hipotezę o heterogeniczności preferencji względem trendujących utworów muzycznych.

Zaobserwowano również, że badane utwory często pojawiały się na playlistach o tytułach sugerujących, iż są to zbiory kompozycji zasłyszanych w innych mediach (np. playlisty o tytułach *Liked from Radio* czy *My Shazam Tracks*). Wykazano również strukturę rynku, według której 45,69% ogółu badanych utworów stanowią utwory o skrajnie długim czasie trwania, 40,31% utwory o bardzo wyrazistym charakterze energicznym, a 39,66% utwory o relatywnie wysokim poziomie melancholii.

Ponadto, na podstawie dostępnej literatury potwierdzono możliwość występowania zjawiska „TikTok-to-Spotify pipeline”. Jednakże, z powodu braku odpowiednio wysokiej jakości danych, nie przeprowadzono w pełni empirycznej analizy tego zagadnienia.

PODSUMOWANIE

Cel pracy został osiągnięty poprzez zastosowanie jednej z technik uczenia maszynowego – klastrowania K-średnich z metryką euklidesową – oraz użycie szeregu testów i procedur statystycznych. Przeprowadzone klastrowanie pozwoliło na zidentyfikowanie 5 grup, które cechują się heterogenicznością między sobą oraz homogenicznością wewnątrz. Klastrom nadano empiryczne charakterystyki oraz zbadano pochodzenie utworów znajdujących się w poszczególnych klastrach za pomocą przyłączenia bazy danych zawierającej playlisty użytkowników Spotify. Porównanie cech klastrów parami pozwoliło także na określenie struktury aktualnych list przebojów. Rozważaniom poddano również zjawisko „TikTok-to-Spotify pipeline” oraz jego podłoże i wpływ na branżę muzyczną oraz kształtowanie się preferencji konsumentów.

Udało się również pozytywnie zweryfikować hipotezę badawczą głoszącą, iż istnieje heterogeniczność preferencji względem trendujących utworów muzycznych. Przytoczone wcześniej klastrowanie potwierdziło dywersyfikację preferencji konsumentów względem najpopularniejszych utworów, która jednak nie przekłada się na różnicę w liczbie odtworzeń utworów.

Jednakże, do wyników niniejszego badania powinno się podchodzić z ostrożnością. Należy pamiętać, iż badanie to dotyczy jedynie relatywnie wąskiego okresu obserwacji i może nie być odporne na dalsze etapy „mediamorfozy”. Warto zatem przeprowadzać analogiczne badanie dla bardziej aktualnych danych, aby zapewnić stały monitoring struktury rynku muzycznego oraz preferencji konsumentów. Ponadto, baza danych użyta w analizie składała się jedynie z utworów najpopularniejszych. Zatem zasadne wydaje się dalsze badanie utworów relatywnie mniej popularnych. Należałoby również poddać analizie zauważone zjawisko „TikTok-to-Spotify pipeline”, którego z powodu braku wystarczającej ilości danych nie udało się zbadać w niniejszej pracy. Ponadto, wskazuje się na innowacyjne zastosowanie techniki „foresight” w kontekście przewidywania komercyjnego sukcesu utworu jako elementu obszaru „Hit Song Science”. Rekomenduje się zastosowanie metody delfickiej przy szacowaniu potencjału utworu na odniesienie komercyjnego sukcesu (ang. *hit potential*) z uwzględnieniem trendu kształtowania się wartości poszczególnych atrybutów muzycznych w szerszej perspektywie czasowej. Ponadto, zaleca się rozważenie użycia w przyszłych analizach bardziej kompleksowych technik uczenia maszynowego, a w szczególności techniki lasów losowych (ang. *random forest*) oraz XGBoost.

BIBLIOGRAFIA

- Askin, N. & Mauskopf, M. (2017). What Makes Popular Culture Popular? Product Features and Optimal Differentiation in Music. *American Sociological Review*, 82(5), 910-944.
- Benetos, E., Ragano, A., Sgroi, D. i inni (2022). Measuring national mood with music: using machine learning to construct a measure of national valence from audio data. *Behavioral Research*, 54, 3085–3092.
- Bonini, T. & Gandini, A. (2019). “First Week Is Editorial, Second Week Is Algorithmic”: Platform Gatekeepers and the Platformization of Music Curation. *Social Media + Society*, 5(4).
- Borghi, M., Maggiolino, M., Montagnani, M. L. & Nuccio, M. (2012). Determinants in the online distribution of digital content: An exploratory analysis. *European Journal for Law and Technology*, 3(2), 1–29.
- Chandrasekhar, T., Thangavel, K. & Elayaraja, E. (2011). Effective Clustering Algorithms for Gene Expression Data. *International Journal of Computer Applications*, 32(4), 25-29.
- Cieślak, J. (2023). Spotify. Polski rynek jest wyjątkowy [Online]. Dostępne na: <https://www.rp.pl/muzyka-popularna/art38167021-spotify-polski-rynek-jest-wyjatkowy> [Dostęp: 30.04.2024]
- Çimen, A. & Kayis, E. (2021). A longitudinal model for song popularity prediction. In *Int’l Conf. on Data Science, Technology and Applications (DATA)*, 96–104.
- Connolly, M. & Krueger, A. B. (2005). *Rockonomics: the economics of popular music*. National Bureau of Economic Research.
- Datta, H., Knox, G. & Bronnenberg, B. (2017). Changing Their Tune: How Consumers' Adoption of Online Streaming Affects Music Consumption and Discovery. *SSRN Electronic Journal*.

- Dixit, A. K. & Stiglitz, J. E. (1977). Monopolistic Competition and Optimum Product Diversity. *The American Economic Review*, 67(3), 297–308.
- Fidler, R. (1997). *Mediamorphosis. Understanding New Media*. Thousands Oaks.
- Fivelsdal, H. (2005). Moving toward a balanced and effective response to Internet music piracy. *International Journal on Media Management*, 7(3), 121-126.
- Fleicher, R. & Snickars, P. (2017). Discovering Spotify - A Thematic Introduction. *Culture Unbound: Journal of Current Cultural Research*. 9. 130-145.
- Fleischer, R. (2021). Universal Spotification? The shifting meanings of “Spotify” as a model for the media industries, *Popular Communication*, 19(1), 14-25.
- Freyhult, E., Landfors, M., Önskog, J. i inni (2010). Challenges in microarray class discovery: a comprehensive examination of normalization, gene selection and clustering. *BMC Bioinformatics*, 11, 503.
- Hartigan, J. A. & Wong, M. A. (1979). A K-Means Clustering Algorithm. *Applied Statistics*, 28, 100.
- Haynes, J. & Marshall, L. K. R. (2017). Beats and tweets: social media in the careers of independent musicians. *New Media & Society*, 20(5), 1973-1993.
- Herremans, D., Martens, D. & Sörensen, K. (2014). Dance hit song prediction. *Journal of New Music Research*, 43(3), 291-302.
- Hracs, B. & Webster, J. (2020). From selling songs to engineering experiences: exploring the competitive strategies of music streaming platforms. *Journal of Cultural Economy*, 14(2), 240-257.
- International Federation of the Phonographic Industry (2020). *Global Music Report: The Industry in 2019*.

- Jakubowicz, K. (2011). *Nowa ekologia mediów. Konwergencja a metamorfoza*. Warszawa: Poltext.
- Jamnejad, M. I., Heidarzadegan, A. & Meshki, M. (2014). Text recognition with k-means clustering. *Research in Computing Science*, 84(1), 29-40.
- Jarque, C. & Bera, A.K. (1980). Efficient Test for Normality, Heteroscedasticity and Serial Independence of Regression Residuals. *Economic Letters* 6, 255-259.
- Jupowicz-Ginalska, A., Kisilowska, M., Jasiewicz, J., Baran, T., & Wysocki, A. (2019). FOMO 2019. Polacy a lęk przed odłączeniem – raport z badań. Warszawa: Wydział Dziennikarstwa, Informacji i Bibliologii Uniwersytetu Warszawskiego.
- Kaimann, D., Tanneberg, I., & Cox, J. (2020). “I will survive”: online streaming and the chart survival of music tracks. *Managerial and Decision Economics*, 42(1), 3-20.
- Kaur, M., Kaur, N. & Singh, H. (2014). Adaptive k-means clustering techniques for data clustering. *International Journal of Innovative Research in Science, Engineering and Technology*, 03(09), 15851-15856.
- Kim, S. T. & Oh, J. H. (2021). Music intelligence: Granular data and prediction of top ten hit songs. *Decision Support Systems*. 145. 113535.
- Kowalski, T. (2017). Między efektywnością a wolnością. Wprowadzenie do ekonomiki selekcji algorytmicznej. *Studia Medioznawcze*, 4(71), 27–36.
- Kruskal, W. H. & Wallis, W. A. (1952). Use of Ranks in One-Criterion Variance Analysis. *Journal of the American Statistical Association*, 47(260), 583–621.
- Lee, C. & Chen, C. (2021). Impulse buying behaviors in live streaming commerce based on the stimulus-organism-response framework. *Information*, 12(6), 241.

- Magiera, R. (2018). *Modele i metody statystyki matematycznej. Część II: Wnioskowanie statystyczne. Wydanie III rozszerzone.* Wrocław: Oficyna Wydawnicza GiS.
- Mann, H.B. & Whitney, D.R. (1947) On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. *Annals of Mathematical Statistics*, 18, 50-60.
- Montecchio, N., Roy, P. & Pachet, F. (2019). The skipping behavior of users of music streaming services and its relation to musical structure.
- Moreau, F. & Bacache-Beauvallet, M. (2016). Information asymmetry and 360-degree contracts in the recorded music industry. *Revue d'Économie Industrielle*, (156), 57-90.
- MRC Data (2020). US TikTok Marketing Science, Music Perceptions Research.
- Mühlbach, S. & Arora, P. (2020). Behind the music: How labor changed for musicians through the subscription economy. *First Monday*, 25.
- Nijkamp, R. (2018). Prediction of product success: explaining song popularity by audio features from Spotify data.
- Oliveira, G. P., Barbosa, G. R. G. i inni (2022). Musical success in the United States and Brazil: novel datasets and temporal analyses. *Journal of Information and Data Management*, 13(1).
- Pachet, F. (2011). Hit song science. W: Tao, L., Mitsunori, O., Tzanetakis, G. red. *Music Data Mining*. New York: CRC Press, 305–326.
- Prey, R. (2020). Locating Power in Platformization: Music Streaming Playlists and Curatorial Power. *Social Media + Society*, 6(2).
- Przybylski, A.K., Murayama, K., DeHaan, C.R., Gladwell, V. (2013). Motivational, emotional, and behavioral correlates of fear of missing out. *Computers in Human Behavior*, 29(4), 1841–1848.

Rahmadania, A. & Sanyata, S. (2023). Fear of missing out in the workplace: a systematic literature review. *International Journal of Multicultural and Multireligious Understanding*, 10(11), 73.

Recording Industry Association of America (2019). Year-end 2019 RIAA music revenues report.

Reiman, M. & Örnell, P. (2018). Predicting Hit Songs with Machine Learning.

Riordan, B. C., Flett, J. A. M., Hunter, J., Scarf, D. & Conner, T. S. (2015). Fear of missing out (fomo): the relationship between fomo, alcohol use, and alcohol-related consequences in college students. *Journal of Psychiatry and Brain Functions*, 2(1), 9.

Ruckenstein, M. & Granroth, J. (2020). Algorithms, advertising and the intimacy of surveillance. *Journal of Cultural Economy*, 13(1), 12–24.

Schriewer, K. & Bulaj, G. (2016). Music Streaming Services as Adjunct Therapies for Depression, Anxiety, and Bipolar Symptoms: Convergence of Digital Technologies, Mobile Apps, Emotions, and Global Mental Health. *Front Public Health*, 4(6), 217.

Sekścińska, K. & Jaworska, D. (2022). Who felt blue when Facebook went down? - The role of self-esteem and FoMO in explaining people's mood in reaction to social media outage. *Personality and Individual Differences*, 188.

Spotify (2024). About Spotify [Online]. Dostępne na: <https://newsroom.spotify.com/company-info/> [Dostęp: 06.05.2024]

Swant, M. (2019). Spotify Rolls Out New ‘Wrapped’ Campaign To Help Users Remember Their Decade Of Music. *Forbes* [Online]. Dostępne na: <https://www.forbes.com/sites/martyswant/2019/12/17/spotify-rolls-out-new-wrapped-campaign-help-users-remember-their-decade-of-music/?sh=5e1c67a710ea> [Dostęp: 30.04.2024]

- TikTok (2021). New studies quantify TikTok's growing impact on culture and music [Online].
Dostępne na: <https://newsroom.tiktok.com/en-us/new-studies-quantify-tiktoks-growing-impact-on-culture-and-music> [Dostęp: 30.04.2024]
- Tofalvy, T. & Koltai, J. (2023). “Splendid Isolation”: The reproduction of music industry inequalities in Spotify’s recommendation system. *New Media & Society*, 25(7), 1580-1604.
- Vall, A., Dorfer, M., Eghbal-zadeh, H., Schedl, M., Burjorjee, K. M. & Widmer, G. (2019). Feature-combination hybrid recommender systems for automated music playlist continuation. *User Modeling and User-Adapted Interaction*, 29(2), 527-572.
- Vox (2022). We tracked what happens after TikTok songs go viral [Online]. Dostępne na: <https://www.youtube.com/watch?v=S1m-KgEpoow> [Dostęp: 30.04.2024]
- Vox. (brak daty). The Unlikely Odds of Making it Big on TikTok [Online]. The Pudding. Dostępne na: <https://pudding.cool/2022/07/tiktok-story/> [Dostęp: 30.04.2024]
- Wang, R., Tang, Y., Liu, G., & Li, Y. (2011). K-means clustering algorithm application in university libraries. *IEEE 10th International Conference on Cognitive Informatics and Cognitive Computing (ICCI-CC'11)*.
- Wikstrom, P. (2009). *The Music Industry*. Cambridge: Polity Press.
- Wlömert, N. & Papies, D. (2016). On-demand streaming services and music industry revenues — Insights from Spotify's market entry. *International Journal of Research in Marketing*, 33(2), 314-327.
- Zhang, T. & Gu, M. (2015). Research on the influence of several factors on clustering results using different algorithms. *The Open Cybernetics & Systemics Journal*, 9(1), 1099-1106.

ZESTAWIENIE SPISÓW

Wykaz skrótów

HSS	- Hit Song Science
MIR	- Music Information Retrieval
FOMO	- Fear Of Missing Out

Spis tabel

Tabela 1.	Opis zmiennych w bazie danych służącej do klastrowania	15
Tabela 2.	Wartości współczynnika Silhouette dla poszczególnych ilości klastrów	24
Tabela 3.	Największa ilość wystąpień utworów w playlistach według klastrów	27
Tabela 4.	Wartości p-value przekraczające przyjęty poziom istotności (5%) podczas stosowania procedury Manna-Whitneya	35
Tabela 5.	Wartości współczynnika Giniego w podziale na klastry	36
Tabela 6.	Wartości współczynnika Giniego dla wybranych zmiennych oraz klastrów	36

Spis rysunków

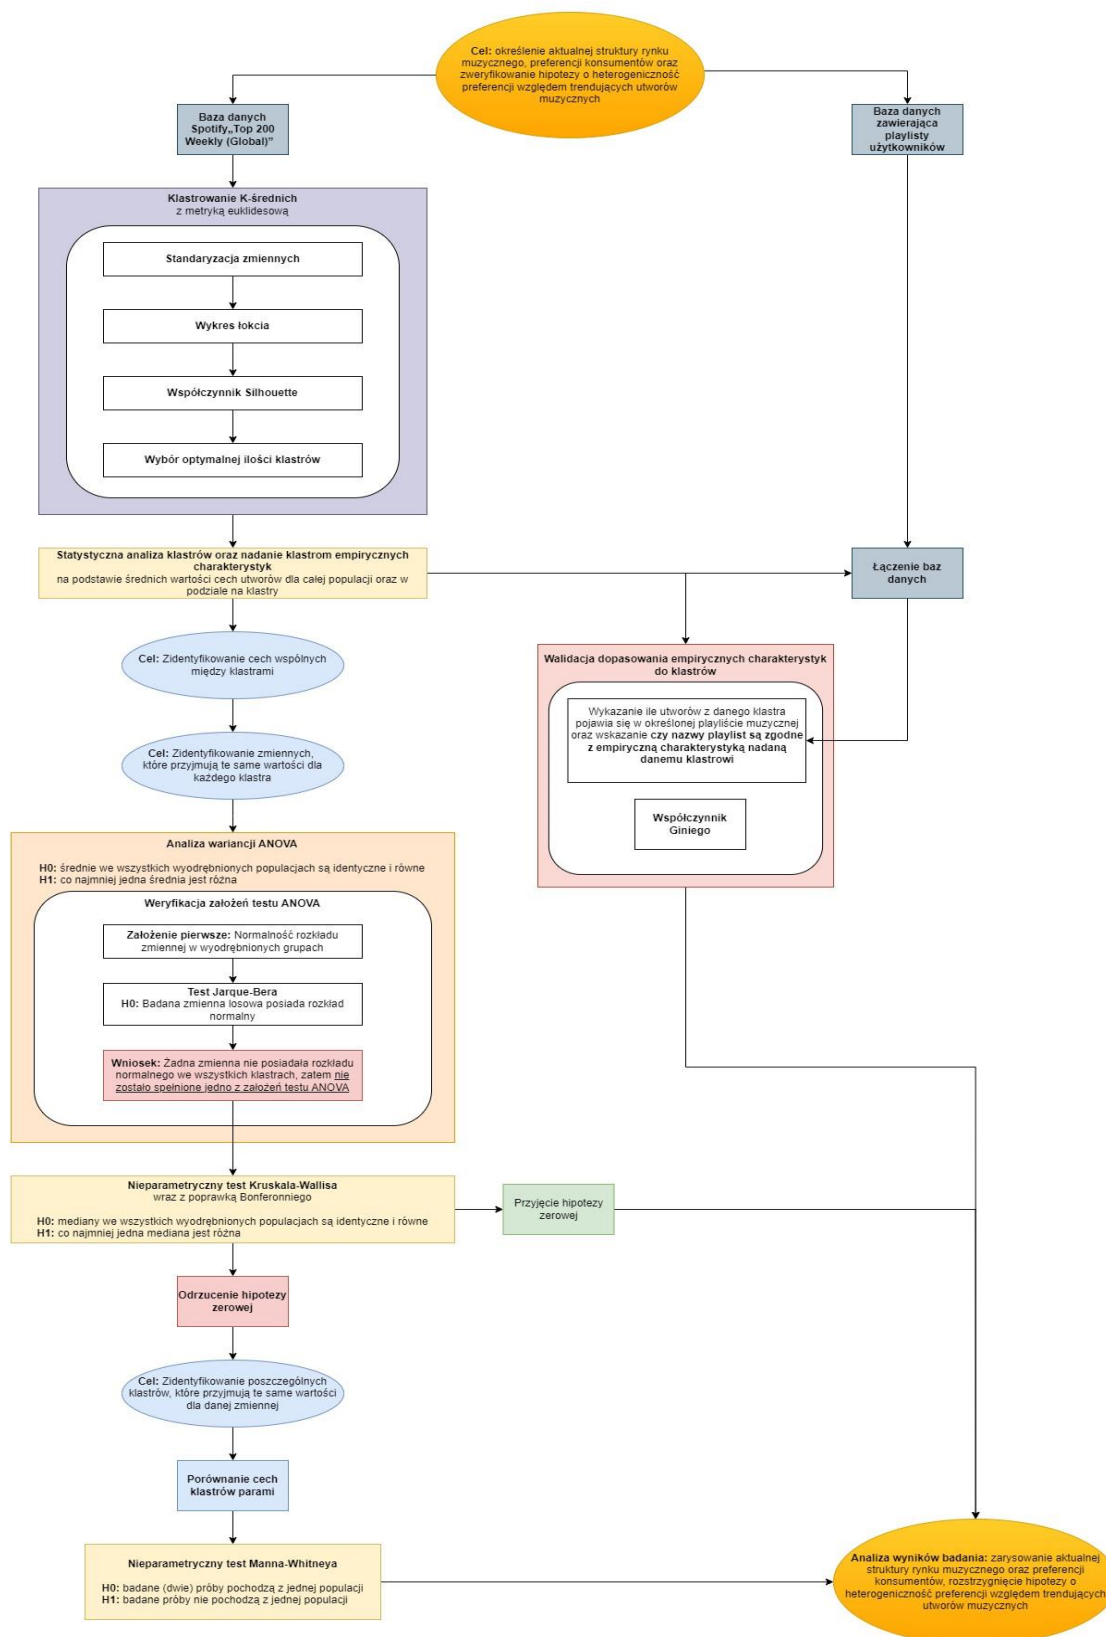
Rys. 1.	Udział dużych wydawnictw muzycznych w ogóle odtworzeń utworów na platformie Spotify	8
Rys. 2.	Spotify jako połączenie trzech różnych rynków	13
Rys. 3.	Wykres łokcia	23
Rys. 4.	Struktura klastrów	24
Rys. 5.	Wykresy pudełkowe klastrów	26
Rys. 6.	Wpływ zjawiska „TikTok-to-Spotify pipeline” na ilość słuchaczy artysty „JVKE”	30
Rys. 7.	Przypuszczalna postać zjawiska „TikTok-to-Spotify pipeline”	32

Spis załączników

Załącznik 1.	Uogólniona metodyka badania	47
Załącznik 2.	Średnie wartości zmiennych w podziale na klastry	48
Załącznik 3.	Średnie wartości zmiennych dla całej populacji	48

ZAŁĄCZNIKI

Załącznik 1. Uogólniona metodyka badania



Załącznik 2. Średnie wartości zmiennych w podziale na klastry

Klaster	0	1	2	3	4
Valence	0,33	0,71	0,52	0,38	0,51
Duration (ms)	204487,56	197397,00	187577,72	199438,67	203754,46
Tempo	123,79	120,95	129,73	115,46	121,85
Liveness	0,15	0,16	0,15	0,15	0,61
Acousticness	0,18	0,18	0,17	0,73	0,22
Speechiness	0,07	0,08	0,29	0,06	0,15
Energy	0,62	0,73	0,62	0,38	0,73
Danceability	0,64	0,75	0,77	0,55	0,63

Załącznik 3. Średnie wartości zmiennych dla całej populacji

Zmienna	Średnia
<i>Danceability</i>	0,69
<i>Energy</i>	0,63
<i>Speechiness</i>	0,12
<i>Acousticness</i>	0,25
<i>Liveness</i>	0,18
<i>Tempo</i>	122,83
<i>Duration (ms)</i>	197988,04
<i>Valence</i>	0,51